Языковое моделирование Лекция 1

Постановка задачи языкового моделирования и метрики качества

План занятия

- 1. Понятие языкового моделирования
- 2. Языковые модели в реальном мире
- 3. Формальная постановка задачи
- 4. Перплексия

Понятие языкового моделирования

Языковая модель предсказывает вероятность следующего слова на основе предыдущих:

Понятие языкового моделирования

Языковая модель предсказывает вероятность следующего слова на основе предыдущих:

Студенты открыли свои

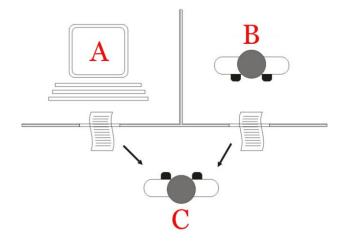
Контекст

Понятие языкового моделирования

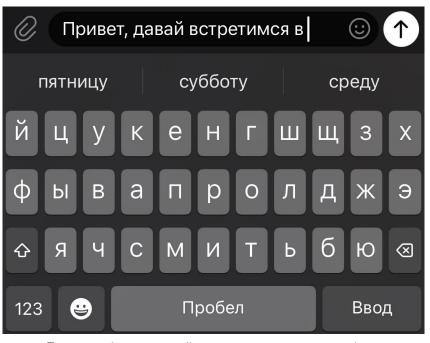
Языковая модель предсказывает вероятность следующего слова на основе предыдущих:



Тест Тьюринга

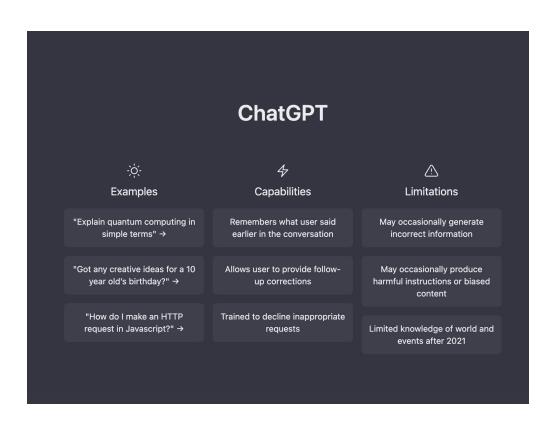


Языковые модели вокруг нас



Пример работы языковой модели в клавиатуре смартфона

ChatGPT тоже является языковой моделью



Формальная постановка

Каждое слово w_i лежит в словаре V

Формальная постановка

Каждое слово w_i лежит в словаре V

Моделируем вероятностное распределение следующего слова при условии предыдущих:

$$P_{\theta}(w_i | w_{i-1}, ..., w_0)$$

Формальная постановка

Каждое слово w_i лежит в словаре V

Моделируем вероятностное распределение следующего слова при условии предыдущих:

$$P_{\theta}(w_i | w_{i-1}, ..., w_0)$$

Мы оцениваем вероятность слова w_i быть следующим, если нам известны слова $w_0,...,w_{i-1}$

Посчитаем вероятность текста

С помощью языковой модели можно оценить вероятность конкретного текста: w_0, \dots, w_k

$$P(w_0, w_1, ..., w_k) = \prod_{i=0}^{K} P(w_i | w_{i-1}, ..., w_0)$$

Посчитаем вероятность текста

На практике гораздо удобнее оценивать логарифм вероятности:

$$\log[P(w_0, w_1, ..., w_k)] = \log[\prod_{i=0}^k P(w_i | w_{i-1}, ..., w_0)] = \sum_{i=0}^k \log[P(w_i | w_{i-1}, ..., w_0))]$$

Исходный текст: студенты открыли свои книги

Исходный текст: студенты открыли свои книги

P(студенты) = 0.4

Исходный текст: студенты открыли свои книги

P(студенты) = 0.4

P(открыли|студенты) = 0.2

Исходный текст: студенты открыли свои книги

P(студенты) = 0.4

P(открыли|студенты) = 0.2

P(свои|студенты, открыли) = 0.7

Исходный текст: студенты открыли свои книги

P(студенты) = 0.4

P(открыли|студенты) = 0.2

P(свои|студенты, открыли) = 0.7

P(книги|студенты, открыли, свои) = 0.3

Исходный текст: студенты открыли свои книги

P(студенты) = 0.4

P(открыли|студенты) = 0.2

P(свои|студенты, открыли) = 0.7

P(книги|студенты, открыли, свои) = 0.3

Тогда логарифм общей вероятности текста:

log[P(студенты открыли свои книги)] = log(0.4) + log(0.2) + log(0.7) + log(0.3) = -4.08

Формула перплексии

В общем случае:

$$PP(w) = \sqrt[k]{\frac{1}{\prod_{i=0}^{k} P(w_i | w_{i-1}, ..., w_0)}} = \exp\left(-\frac{1}{k} \sum_{i=0}^{k} \log P(w_i | w_{i-1}, ..., w_0)\right)$$

Формула перплексии

В общем случае:

$$PP(w) = \sqrt[k]{\frac{1}{\prod_{i=0}^{k} P(w_i | w_{i-1}, ..., w_0)}} = \exp\left(-\frac{1}{k} \sum_{i=0}^{k} \log P(w_i | w_{i-1}, ..., w_0)\right)$$

Для примера с прошлого слайда:

$$\exp\left(\frac{1}{4} \cdot 4.08\right) \approx 2.77$$

Важно: чем ниже перплексия, тем лучше.

Почему языковое моделирование — важная задача?

- 1. Языковые модели являются компонентом многих других задач в NLP, связанных с генерацией или оценкой вероятности текста:
 - автодополнение текста,
 - исправление грамматических ошибок,
 - машинный перевод,
 - распознавание речи,
 - ...
- 2. Языковые модели бенчмарк, который оценивает текущий прогресс в NLP

Итоги занятия

Сегодня мы узнали:

- что такое языковые модели и для чего они нужны,
- как оценивать качество языковых моделей с помощью перплексии,

В следующем видео мы поговорим о том, как решать задачу языкового моделирования с помощью N-грамм.